S O F T W A R E D E S I G N A N D A R C H I T E C T U R E

智问校园 Campus Mind 设计与架构文档

软件设计说明书(SDD)+ 软件架构文档(SAD)合并 · v1.0

《软件体系结构》课程项目 · 2026 春季学期

团队：王若璋 · 何俪 · 郭祖梁

2026 年 10 月

目　录

1 引言.....1

1.1 编写目的与文档关系.....1

1.2 范围与读者.....1

2 架构总览.....2

2.1 架构风格与总体形态.....2

2.2 分层职责.....2

2.3 技术选型与约束.....2

3 架构描述:4+1 视图.....3

3.1 逻辑视图(功能分解).....3

3.2 进程视图(并发与同步).....3

3.3 开发视图(代码组织).....4

3.4 物理视图(部署拓扑).....5

3.5 场景视图(端到端用例走查).....5

4 详细设计:RAG 检索引擎.....6

4.1 双通道检索.....6

4.2 RRF 融合与质量控制.....6

4.3 重排序(实验开关).....6

4.4 参数标定(评测驱动).....7

5 数据库设计.....7

5.1 存储划分与 ER 关系.....7
5.2 表结构.....7
5.3 演进设计.....8
6 接口设计.....8
6.1 问答接口(SSE).....8
6.2 知识与运维接口.....8
7 前端设计(SPA).....9
8 部署与运维.....9
8.1 配置项(环境变量).....9
8.2 扩展三级与反向代理要点.....10
9 架构决策记录(ADR).....10
ADR-1 模块化单体起步,预留服务化边界.....10
ADR-2 混合检索 + RRF 融合.....11
ADR-3 SSE 承载流式输出.....11
ADR-4 生成 Provider 插件化 + 熔断降级.....12
ADR-5 内存索引热重建.....12
ADR-6 令牌桶入口限流.....13
ADR-7 Embedding Provider 可插拔,TF-IDF 为离线 fallback.....13
10 质量证据与需求追踪.....14
10.1 检索评测(n=62 口语化改写,统一文档级去重口径).....14
10.2 性能基准与架构验收.....14
10.3 追踪矩阵.....15

注：本目录由域代码生成，如编辑后页码变动，请右键目录选择「更新域」刷新。

1 引言

1.1 编写目的与文档关系

本文档是《软件需求规格说明书(SRS)》的设计侧承接,合并软件设计文档(SDD,模块/数据/接口的详细设计)与软件架构文档(SAD,多视图架构描述与决策记录)为一册:第 2-3 章为架构描述(SAD),第 4-7 章为详细设计(SDD),第 8-10 章为部署、决策与质量证据。需求编号 FR-x / NFR-x 与 SRS 一致,追踪矩阵见第 10 章。

1.2 范围与读者

覆盖后端(app/api、services、repository、core 四分包)、前端原生 SPA 与评测工具链的全部设计决策;预期读者为课程指导教师、项目组成员与后续维护者。文档中全部指标为 2026-10-16 复测实测值,复现方法见 docs/REPRODUCIBILITY.md。

2 架构总览

2.1 架构风格与总体形态

系统采用分层风格的模块化单体:五层单向依赖、进程内调用,以分包边界预留服务化拆分点(ADR-1)。演示形态为单进程零外部依赖;生产形态通过反向代理与多实例水平扩展(第 8 章),无需修改应用代码。



图 2-1 五层分层架构(接入 → 网关边界 → 应用服务 → RAG 引擎 → 数据)

2.2 分层职责

表 2-1 分层职责与技术选型

层次	职责	主要构件
接入层	用户交互与流式渲染	原生 SPA 三视图(问答/知识库/看板),SSE 解析,输出全量转义
网关边界	限流、鉴权、跨域	令牌桶(5 QPS/突发 10,桶字典有界)、ADMIN_TOKEN 写鉴权、会话属主校验(F10)、CORS
应用服务	用例编排	chat(SSE 问答)、knowledge(增删查+热更新)、conversations、admin(统计)
RAG 引擎	检索与生成	BM25Index(倒排)、VectorIndex(TF-IDF/embedding-3)、fuse_rrf、Reranker 开关、GeneratorProvider
数据层	持久化与语料	SQLite(WAL,会话/消息/查询日志)、campus_qa.json 知识语料、内存索引(热重建)

2.3 技术选型与约束

- 后端 Python 3.10+ / FastAPI / uvicorn;分词 jieba;HTTP 客户端 httpx;测试 pytest
- 约束 C-1 零依赖演示:C-2 Provider 可插拔(ADR-4/ADR-7);C-4 如实原则(引擎信息可见)

- 选型理由:FastAPI 原生 async 承载 SSE 流;自实现 BM25/RRF 保证算法可解释、可评测、零模型依赖

3 架构描述:4+1 视图

3.1 逻辑视图(功能分解)

最终用户视角的功能结构。检索引擎 HybridRetriever 聚合稀疏通道 BM25Index(倒排索引 + k1=1.5/b=0.75)、稠密通道 VectorIndex(EmbeddingProvider 抽象:TF-IDF 词袋或智谱 embedding-3)与 fuse_rrf 融合;生成端 GeneratorProvider 具有本地抽取式与智谱 GLM 两个实现;ingestion 负责语料摄取、QA 双通道分块与热重建。

表 3-1 逻辑构件与职责

构件	位置	职责
HybridRetriever	services/retrieval.py	双通道检索编排、RRF 融合、文档级去重、无知识兜底
GeneratorProvider	services/generation.py	流式生成抽象;本地抽取式/云端 GLM;异常熔断降级
ingestion	services/ingestion.py	语料装载、q/a 分块(答案按 3 句滑窗)、统一文件锁热更新
api 路由组	app/api/*	chat / knowledge / conversations / admin 四组 HTTP 用例
repository.db	repository/db.py	SQLite 仓储:会话、消息、查询日志(接口隔离 SQL)
security	core/security.py	令牌桶限流(有界淘汰)与 ADMIN_TOKEN 写鉴权

3.2 进程视图(并发与同步)

- 运行时为单进程 asyncio 事件循环:chat 以流式生成器逐事件推送 SSE,不阻塞其它请求

- 并发控制:入口令牌桶按用户隔离;桶字典上限 1 万、最久未活跃淘汰,防伪造令牌内存耗尽
- 热更新同步:ingestion 持文件锁串行化「读语料-写文件-重建索引」,新增与删除共用一把锁(F8 修复)
- SQLite 连接为线程局部并开启 WAL,读多写少场景并发安全

3.3 开发视图(代码组织)

- backend/app 四分包 api / services / repository / core,依赖方向单向:api → services → repository/core
- frontend 原生三文件 SPA(index.html / app.js / style.css),无构建链;scripts 为评测工具链(eval_matrix / bench / acceptance);tests 含冒烟与完善轮回归共 13 项
- 构建与文档脚本位于 .build/(deck 与 docx 生成均可在本机一键复现)

3.4 物理视图(部署拓扑)

图 3 部署视图:单机演示 → 生产集群的演进路径



图 3-1 部署拓扑与演进(演示单机 → Nginx 反代多实例 → 限流外置)

演示形态:浏览器直接访问 uvicorn(127.0.0.1:8000,同源托管前端静态资源)。生产形态:Nginx 终止 TLS 并反代 /api(proxy_buffering off 保 SSE 直通,proxy_read_timeout ≥ 60s),静态资源直出;多实例共享外置数据;云端 GLM/embedding 为可选外部服务,异常自动降级本地。

3.5 场景视图(端到端用例走查)

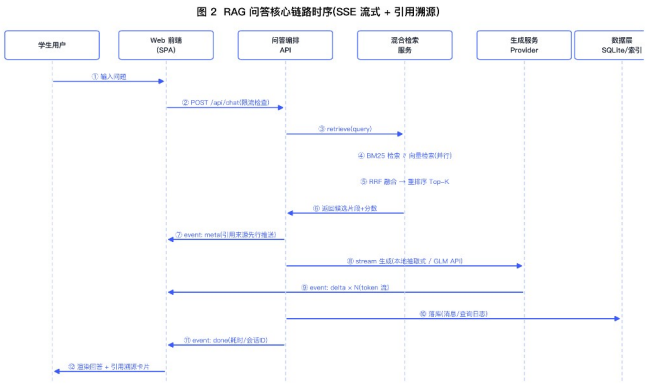


图 3-2 一次问答的时序:检索、融合、流式生成与引用溯源

以「图书馆开放时间是几点」走查:浏览器 POST /api/chat → 网关限流校验(进程视图)→ HybridRetriever 双通道检索与 RRF 融合(逻辑视图)→ meta 事件先推引用来源 → GeneratorProvider 流式生成 → 消息与查询日志落库(数据层)→ 引用卡片渲染。该场景贯穿四视图,是验收 A1-A4 的载体。

4 详细设计:RAG 检索引擎

4.1 双通道检索

- 稀疏通道 BM25:jieba lcut_for_search 分词(停用词过滤),倒排索引(词→{文档:词频})查询仅访问命中词倒排链;与暴力扫描逐位等价(单元测试校验),当前语料 10 倍、20 倍语料 35 倍吞吐(F6)
- 稠密通道:演示环境 TF-IDF 加权词袋(与 BM25 共享 idf);生产切智谱 embedding-3(批量嵌入 + 内存缓存),接口不变

4.2 RRF 融合与质量控制

融合公式为标准 RRF:score(d) = Σ_channel 1/(RRF_K + rank),RRF_K=60,对排名融合、免分数归一化(完善轮 F1 将常数权重修正为排名权重,为语义通道预留正确行为)。质量控制包含文档级去重(同文档 q/a 双通道 chunk 仅保留最高分,避免挤占名额)与无知识硬零兜底(候选与查询实质词零交集即判无知识,触发 FR-6)。

4.3 重排序(实验开关)

LightweightReranker 为特征化词面重排(实质词覆盖/二元词重叠/句子级重叠/标签信号);62 条评测显示其无稳定收益(Hit@1 77.4% vs RRF 80.6%),故 RERANK_ENABLED 默认关闭,保留 Provider 化接口,计划替换 Cross-Encoder(bge-reranker)后重评。

4.4 参数标定(评测驱动)

表 4-1 关键参数与标定依据

参数	取值	标定依据
CHUNK_TOP_K / FINAL_TOP_K	5 / 3	融合候选与最终上下文条数,Top-3 已覆盖 98.4% 正解
RRF_K	60	标准取值;对排名融合,语料规模不敏感
MIN_RELEVANCE	0.08	62 条标定:0.15 误杀口语化正解,0.06 放入无关命中

5 数据库设计

5.1 存储划分与 ER 关系

- 关系数据(SQLite):conversation 会话 1→N message 消息;query_log 查询日志独立追加,不关联个人
- 文档数据(JSON):知识语料 campus_qa.json,摄取为 136 个双通道 chunk(question 通道管问法匹配,answer 通道按 3 句滑窗管内容覆盖,同 doc_id 关联引用溯源)
- 内存数据:BM25 倒排与向量矩阵构成检索索引,版本号递增,热更新免重启重建

5.2 表结构

表 5-1 关系表结构(SQLite DDL 摘要)

表	字段	说明
conversation	id PK / user_token / title / created_at / updated_at	用户令牌隔离;标题取首问前 24 字

表	字段	说明
message	id PK / conversation_id FK / role / content / sources(JSON) / latency_ms / created_at	sources 保存引用来源快照,支撑历史回放
query_log	id PK 自增 / ts / query / hit / top_score / latency_ms / category	看板聚合源;仅追加

5.3 演进设计

- 仓储模式隔离 SQL:repository/db.py 对上仅暴露函数接口,替换 PostgreSQL 只改实现不改调用方(NFR-6)
- 知识文件与索引共用一把文件锁双写一致(F8);SQLite 开 WAL 支持并发读

6 接口设计

6.1 问答接口(SSE)

POST /api/chat,请求体 {message, conversation_id?},响应为 text/event-stream 事件序列:meta(会话 id、检索耗时、引用来源数组、引擎名)→ delta(增量文本)多次 → done(消息 id、总耗时);流内异常推送 error 事件。429 表示触发限流。

6.2 知识与运维接口

表 6-1 API 摘要(与 SRS 表 6-1 对应)

端点	方法	语义	关键行为
/api/knowledge	GET	分页列表	category / q 过滤;分类集合基于全量计算
/api/knowledge	POST	批量新增	锁内追加+热重建,版本递增;ADMIN_TOKEN 启用时需 X-Admin-Token
/api/knowledge/{id}	DELETE	删除	remove_document 统一锁;404 不存在
/api/knowledge/search	GET	调试检索	返回双通道排名与融合分数(观测数据不伪造,F2)

端点	方法	语义	关键行为
/api/admin/stats	GET	运行统计	含 llm/embedding provider 与索引版本(如实展示)

7 前端设计(SPA)

- 三视图单页应用:智能问答(流式渲染+引用卡片)、知识库管理(分页/筛选/录入)、运行看板(统计+分类热点)
- SSE 解析:fetch 流式读取,按事件分派;meta 先行渲染引用区,打字机增量渲染回答
- 安全实现:全部 innerHTML 插值经 escapeHtml(来源标题/看板分类/历史回放三处修复,F3);管理令牌按需提示输入并记忆
- 交互细节与状态设计(空态/限流/无知识兜底/降级提示)见《UI 原型》交付物

8 部署与运维

8.1 配置项(环境变量)

表 8-1 配置项

变量	默认	说明
ZHIPUAI_API_KEY	空	配置后生成切 GLM、向量切 embedding-3;异常自动降级
LLM_PROVIDER / EMBEDDING_PROVIDER	local / auto	Provider 显式指定;auto=有 Key 用云端
RERANK_ENABLED	0	重排实验开关(实测无收益,默认关)
RATE_LIMIT_QPS / BURST	5 / 10	单用户令牌桶
ADMIN_TOKEN	空	设置后知识写接口强制 X-Admin-Token(演示开放模式启动时打印提示)

8.2 扩展三级与反向代理要点

- 第一级 uvicorn workers 竖扩;第二级 Nginx 反代多实例(应用无状态,SQLite/索引外置或每实例只读);第三级限流外置 Redis 滑动窗口
- Nginx 要点:proxy_buffering off 保 SSE 直通;proxy_read_timeout ≥ 60s;静态直出与 TLS 终止;limit_req 与应用令牌桶双层限流
- 容量基线:单实例 E2E 42-44 QPS(0 失败),万人在校场景余量 10 倍以上;成本测算见《经济适用型与运营方案》

9 架构决策记录(ADR)

ADR-1 模块化单体起步,预留服务化边界

背景:课程周期 8 周、3 人团队,微服务全栈成本不可承受,但需为演进留路。

决策:五层分包、进程内调用、应用无状态(SQLite/索引可外置)。

后果:正:交付快、调试链路短;负:规模增长后需按边界拆分(已预留在分包与接口设计)。

ADR-2 混合检索 + RRF 融合

背景:规章问答词面匹配强,但口语改写易漏召回,单通道无冗余。

决策:BM25 ‖ 向量双通道,RRF 对排名融合免归一化;文档级去重 + 硬零兜底。

后果:正:Hit@3 98.4%,通道独立演进;负:双索引成本,参数需评测标定。

ADR-3 SSE 承载流式输出

背景:回答生成耗时数百毫秒,同步等待体验差。

决策:meta 先推引用,delta 增量推文,done 收尾;前端打字机渲染。

后果:正:首字即时、可感知进度;负:反向代理需关缓冲(部署清单已列)。

ADR-4 生成 Provider 插件化 + 熔断降级

背景:演示零依赖与生产质量二选一矛盾。

决策:GeneratorProvider 统一流式接口;默认本地抽取式,配 Key 切 GLM;异常流内回退并落日志。

后果:正:演示/生产同构,可用性有硬底(A1 PASS);负:双实现双份测试。

ADR-5 内存索引热重建

背景:知识录入要求免重启生效(<5s)。

决策:摄取服务持锁重建全量索引,版本号递增,前端可见。

后果:正:59 篇/136 chunks 重建 <1s;负:语料巨大时需增量或外置向量库。

ADR-6 令牌桶入口限流

背景:突发流量会拖垮生成与外部 API 配额。

决策:单机令牌桶(5 QPS/突发 10,桶字典有界淘汰);生产外置 Redis。

后果:正:A2 精确放行/拒绝;负:多实例需外置共享限流。

ADR-7 Embedding Provider 可插拔,TF-IDF 为离线 fallback

背景:语义向量依赖外部服务,课程环境不可假设可用。

决策:auto 工厂:有 Key 用 embedding-3(带缓存),否则 TF-IDF;构建失败回退并如实显示。

后果:正:零依赖与语义升级同构;负:TF-IDF 非语义嵌入,须明示(如实原则)。

10 质量证据与需求追踪

10.1 检索评测(n=62 口语化改写,统一文档级去重口径)

表 10-1 四路链路评测(2026-10-16 实测)

链路	Hit@1	Hit@3	MRR
BM25-only	80.6%	98.4%	0.884
Vector-only(TF-IDF)	75.8%	93.5%	0.844

链路	Hit@1	Hit@3	MRR
Hybrid+RRF(生产默认)	80.6%	98.4%	0.882
Hybrid+Rerank(实验开关)	77.4%	96.8%	0.860

10.2 性能基准与架构验收

表 10-2 性能基准(拆分口径)

基准	QPS	p50	p95	p99	失败
retrieval-only(RRF,Win/x64 两次实测)	515.8-880.4	1.1-1.9ms	1.8-3.2ms	2.1-3.7ms	0
E2E 并发 20(含生成+落库)	42.1-43.3	413-425ms	628-647ms	727-761ms	0

- 架构验收 4/4 PASS:A1 生成降级(139 字正解)/ A2 入口限流(200x10+429x5)/ A3 热更新(版本递增)/ A4 无知识兜底(sources=0)
- 单元测试 14/14(冒烟 4 + 回归 10:RRF 公式、倒排等价、鉴权、桶淘汰、删除语义降级日志、会话属主隔离等)

10.3 追踪矩阵

需求 → 质量属性 → ADR → 模块 → 测试 → 证据的完整映射维护于仓库 docs/traceability.md(含 2026-10-16 完善轮 F1-F9 与 2026-10-27 F10 会话越权修复行,见 docs/IMPROVEMENTS.md)。本文档与《SRS》《UI 原型》共同构成课程交付物;仓库 github.com/yelikour/campus-qa(公开)。