智问校园 CampusMind

经济适用型与运营方案

—— 系统怎么卖、真实成本多少、怎么扛并发 ——

《软件体系结构》课程项目补充交付物 · 2026 年 10 月 · 王若璋 · 何俐 · 郭祚梁

口径声明(诚实原则)

本方案所有数字分三类,均如实标注:① 实测数字来自本项目可复现脚本(scripts/bench.py、eval_matrix.py,2026-09-18 运行);② 外部价格为 2026 年 10 月查询的公开市场价/新用户活动价,存在波动与续费涨价风险,以官方页面为准;③ 商业定价(SaaS 订阅价、买断价)为商业假设示例,不是承诺。此外,大模型调用成本一律按真实收费价核算,不依赖任何限时免费活动(现行免费活动仅作如实备注、未计入方案)。四者不混用、不夸大。

1 摘要:为什么「经济适用」是架构决策的自然结果

本系统的全部架构决策(生成端插件化、本地抽取式兜底、内存索引热更新、模块化单体)共同导向一个经济结论:默认链路 0 GPU,云端生成按真实收费价核算在保守档下也仅约两百元/月,一台入门级云服务器即可承载一所高校的日常问答量。这使得系统可以以可控的、可预测的边际成本售卖和运营——免费版靠本地抽取式生成真正零成本获客,付费版在数百元月成本上构建毛利,且任何情况下可切回本地生成,成本存在硬上限。

三个关键事实支撑上述判断:

事实	数值	来源
单实例全链路吞吐(E2E,含流式生成)	44.1 QPS · p99 611ms · 0 失败	scripts/bench.py 实测
云端生成模型按量计费(保守档)	¥1/百万 token → 日均 5,000 问 ≈¥195/月	公开定价档位 × 代码 token 估算
本地兜底生成	内置抽取式生成器,离线 0 成本	代码实现,验收 A1 通过

说明:E2E 指从 HTTP 请求进入至流式回答完成的完整链路;44.1 QPS 为 local-extractive 提供者、并发 20、200 样本的实测口径。

2 售卖模式:三档产品矩阵

按「数据敏感度 × 运维能力」划分客群,提供三档产品形态:

模式	定价(假设示例)	目标客群与场景	我方成本
SaaS 订阅(推荐起步)	¥4,999 /校/年	中小院校/高职:零运维,我方托管,含升级维保,先试用后签约	服务器 + 按量 API(保守价),≈¥210–230/月
私有化部署买断	¥29,999 买断 + 15%/年维保	数据不出校的高校:部署进校园内网,复用校内已有虚拟机	一次性实施(人力),运行成本由校方承担,边际≈0
免费社区版	¥0	获客入口:本项目形态直接可用,本地抽取式生成零 API 成本	近零(用户自部署)

2.1 销售路径

高校信息化采购以年度预算与项目制为主,路径设计为:① 免费社区版在院系/社团级试点,积累真实问答数据与口碑;② 试用期结束后以 SaaS 订阅进入校级预算(定价低于一次人工咨询外包的月度成本);③ 对数据合规要求高的学校升级为私有化买断。三档形态共享同一代码基座,仅为部署方式与合同形态差异——这直接降低了多形态维护成本。

2.2 定价依据

SaaS 年费 ¥4,999 对应我方直接成本约 ¥2,520–2,760/年(服务器 ¥165–379/年+ 域名证书 ≈¥60/年 + 保守档 API ≈¥2,340/年,按日均 5,000 问、¥1/百万 token),毛利率约 44%;若大模型处于历史挂牌价档(GLM-4-Flash 付费时期 ¥0.06–0.1/百万 token),API 仅 ≈¥144–240/年,毛利率升至约 88%。两档真实价位下定价均有安全垫,方案不依赖任何限时免费活动。私有化买断价对标同类校园知识库项目人天实施费(约 15–25 人天)。

3 部署方案与月度成本核算

方案	适用场景	服务器	大模型	月成本估算
A 云端 SaaS(我方托管)	绝大多数学校	轻量 2C4G:阿里云 ¥379/年或腾讯云 ¥165–220/年(新用户活动价)≈¥14–32/月	GLM 按量计费,保守档 ¥1/百万 token(日均 5,000 问 ≈¥195/月);embedding-3 重建 ≈¥0.01/次	≈¥210–230/月
B 私有化 CPU(校内虚机)	数据不出校	复用校内已有虚拟机(2C4G 即可),边际成本 ¥0	校方自备 API Key,或使用本地抽取式(¥0)	边际 ≈ ¥0
C 全离线 GPU(内网隔离)	数据最敏感	RTX 4090 租用包月 ¥1,000–1,500;或买断二手 4090 ≈¥15,000(电费另计 ≈¥190/月)	本地量化模型(GLM/Qwen 7B AWQ · vLLM/Ollama)	≈¥1,000–1,500/月

价格时点 2026-10:轻量服务器为新用户活动价,续费价更高;GPU 价格来自算力租赁平台公开报价区间。方案 C 仅在要求数据完全不出内网时选择,对本项目目标场景(公开校务知识问答)通常不必要。

3.1 部署形态(Docker 单机起步)

生产最小形态为「1 台服务器 + Docker Compose + Nginx」:应用容器(uvicorn --workers 4)+ Nginx 反代(TLS 终止、静态直出、SSE 直通)。无需向量数据库、无需消息队列、无需 GPU——检索索引常驻内存,SQLite 单文件存储,备份即复制文件。

4 大模型调用成本:Token 构成与敏感性测算

4.1 每问 Token 构成(按实现代码估算)

构成	内容	估算量级
系统提示	角色设定+引用约束,约 60 字	≈60 token
检索上下文	Top-3 知识条目(FINAL_TOP_K=3),每条约 150–400 字	≈900 token
用户问题	口语化提问	≈20 token
模型输出	分点回答+来源标注	≈300 token
合计	输入 ≈1,000 + 输出 ≈300	≈1,300 token/问

估算口径:中文按 1 字≈1 token 保守计;实际取决于分词器,量级不变。

4.2 生成端成本:真实收费价三档

计价情景	单价	每问成本	日均 5,000 问月成本
历史挂牌价档(GLM-4-Flash 付费时期公开价)	¥0.06–0.1 / 百万 token	≈¥0.0001	≈¥12–20/月
保守档(方案基准,当代主力模型价位)	¥1 / 百万 token	≈¥0.0013	≈¥195/月
压力上限档	¥5 / 百万 token	≈¥0.0065	≈¥975/月

现行官方对 GLM-4-Flash 有限时免费活动,本方案未计入该优惠,一律按常态收费价核算;免费活动若持续仅为额外安全垫。

三档真实价位下 SaaS 定价均有毛利(§2.2 给出基准档与历史档测算);且系统可随时切回本地抽取式生成(验收 A1 的降级路径),成本存在硬上限——这是「双模生成架构」在商业上的直接价值:API 价格波动不构成经营风险。

4.3 Embedding 成本

embedding-3 约 0.5 元/百万 token 档。当前 62 条知识全量重建 ≈2 万 token ≈¥0.01,仅在知识库变更时发生;扩展到 5,000 条知识(≈160 万 token)单次重建也仅 ≈¥0.8。相对服务器租金可忽略。

4.4 若坚持本地部署大模型(方案 C 补充)

4090(24GB)可流畅运行 7B–14B 量化模型(vLLM,AWQ/GPTQ),满足校园问答质量需求。租用包月 ¥1,000–1,500;若买断二手 4090(≈¥15,000),按电费 450W×24h×30 天×¥0.6/度 ≈¥190/月,约 12–15 个月收回买断成本(相对租用)。注意 2026 年市场仍存在高端卡供应紧张(「抢卡」)现象,采购周期需预留。

5 高并发:实测容量与扩展规划

5.1 容量外推(基于实测)

容量估算口径:日问量集中在约 8 小时活跃时段,峰值按均值×10 保守估计。单实例 44.1 QPS 为下限基准(未开多 worker)。

场景	日问量	峰值 RPS(估)	所需配置	月服务器成本
单校 1 万人	5,000	<3	1× 2C4G 单实例	≈¥32
10 校 SaaS	50,000	≈20–30	1× 4C8G(workers 4)或 2× 2C4G	≈¥65–100
50 校 SaaS	250,000	≈90–150	4× 4C8G + Nginx 负载均衡	≈¥390
远期千级 QPS	—	1,000	≈25 实例 + Nginx	≈¥800

结论:校园场景的并发压力远低于单实例容量(余量 10 倍以上),「高并发」对本系统是线性加机器问题而非架构难题;容量与成本线性挂钩,无雪崩点。

5.2 扩展三级路径

① 进程内:uvicorn --workers 4,同机吞吐约 2–3 倍(CPU 核数限制);② 主机间:Nginx 反向代理多实例负载均衡,应用层无状态设计(会话不落本机),加机器即扩容;③ 组件级:限流计数与会话外置 Redis(与部署演进页的四项替换一致:SQLite→PG、内存索引→Milvus、本地→GLM、代理→Redis)。每一级都是独立的、可单独决策的演进步骤。

6 反向代理与生产部署拓扑(Nginx)

生产拓扑:客户端 → Nginx(443,TLS 终止)→ 应用实例×N(uvicorn :8000)。Nginx 承担四项职责:TLS 终止、静态资源直出、SSE 流式直通、入口级限流。

6.1 关键配置(SSE 直通是重中之重)

```
upstream campusmind {
    least_conn;
    server 127.0.0.1:8000;      # uvicorn app.main:app --workers 4
    # server 10.0.0.12:8000;    # 扩容时追加实例
}
limit_req_zone $binary_remote_addr zone=qa:10m rate=10r/s;
```

```
server {
    listen 443 ssl;
    server_name qa.example.edu.cn;
    ssl_certificate     /etc/letsencrypt/live/qa/fullchain.pem;
    ssl_certificate_key /etc/letsencrypt/live/qa/privkey.pem;

    location /api/ {                        # SSE 流式问答接口
        limit_req zone=qa burst=20 nodelay;   # 入口级限流(第一层)
        proxy_pass http://campusmind;
        proxy_buffering off;                # 关键:SSE 直通,禁用响应缓冲
        proxy_cache off;
        proxy_http_version 1.1;
        proxy_set_header Connection "";
        proxy_read_timeout 60s;             # 防长回答被默认超时掐断
        proxy_set_header X-Real-IP $remote_addr;
        add_header X-Accel-Buffering no; # 双保险
    }
    location /static/ { root /var/www/campusmind; expires 7d; }
    location /  { proxy_pass http://campusmind; }
}
```

6.2 双层限流说明

Nginx limit_req(IP 级,10 r/s+突发 20)负责挡掉恶意脚本与突发扫描;应用内令牌桶(5 QPS/用户,突发 10,验收 A2 实测)负责业务级公平性。两层职责不同:前者保护整机,后者保护单用户体验。生产多实例时应用层限流计数外置 Redis,避免各实例独立计数导致限流阈值被 N 倍放大。

7 运营成本模型:SaaS 单校月度损益示例(真实收费价)

项目	历史挂牌价档(¥0.06–0.1/百万)	保守档(¥1/百万,方案基准)
收入(¥4,999/年 ÷ 12)	¥417/月	¥417/月
服务器(2C4G 活动价)	¥32/月	¥32/月
域名 + TLS(Let's Encrypt 免费,域名 ≈¥60/年)	¥5/月	¥5/月
对象存储备份(≈10GB)	¥3/月	¥3/月
大模型 API(日均 5,000 问,按真实收费价)	¥12–20/月	¥195/月
直接成本小计	≈¥52–60/月	≈¥235/月

项目	历史挂牌价档(¥0.06–0.1/百万)	保守档(¥1/百万,方案基准)
直接毛利	≈¥357–365/月(86–88%)	≈¥182/月(44%)

诚实标注:两列均为真实收费价口径(免费活动未计入,若免费持续仅是额外安全垫)。本表仅含直接资源成本,不含人力(实施、维保响应、知识库代运营)与获客成本;3 人团队按兼职运营假设,10 校规模下人力成本被摊薄,模型才真正成立。

8 风险与局限(如实)

① 计价风险:本方案不依赖限时免费活动,按真实收费价核算;若厂商调价,§4.2 三档区间覆盖至 ¥5/百万 token 仍有毛利,且可随时切回本地抽取式生成(¥0),成本存在硬上限;② 活动价风险:服务器与 GPU 价格引用的是 2026-10 新用户活动价/市场区间,续费与量产价更高,采购前以官方页面为准;③ 并发数字口径:44.1 QPS 为 local-extractive 提供者的实测,云端 GLM 模式下吞吐受 API 时延影响,首字延迟取决于网络;④ token 估算为代码静态估算,非线上埋点实测;⑤ 商业定价为课堂假设,未经真实市场验证;⑥ 方案 C 的 GPU 市场存在供应波动,成本与交付周期需预留余量。

9 价格来源(2026-10 查证)

· 智谱开放平台:GLM-4-Flash 付费时期历史挂牌价 ¥0.06–0.1/百万 token;
当代主力模型公开档位约 ¥1/百万 token;embedding-3 约 0.5 元/百万 token 档。
(现行 GLM-4-Flash 限时免费活动未计入本方案,仅如实备注。)

· 阿里云/腾讯云轻量应用服务器活动价页:2C4G ¥165–379/年;4C8G ¥1,159/年(新用户专享)。

· 算力租赁平台公开报价(AutoDL 等):RTX 4090 时租 ¥1.65–1.98,包月 ¥1,000–1,500;
二手 4090 市场价 ≈¥15,000(2026 年中)。

· 电费按居民/校园电价 ¥0.6/度估算。

· 性能与验收数字:本项目 scripts/bench.py、scripts/acceptance.py 实测存档
(artifacts/final_validation.txt),可复现。